

Аналитический отчёт по курсовой работе

Прогнозирование биологической активности и токсичности соединений методами классического машинного обучения

1. Цель работы

Целью данной курсовой работы являлось построение и сравнительный анализ моделей классического машинного обучения для решения следующих задач на основе набора молекулярных дескрипторов:

1. Регрессия для IC50
2. Регрессия для CC50
3. Регрессия для SI
4. Классификация: превышает ли IC50 медианное значение выборки
5. Классификация: превышает ли CC50 медианное значение выборки
6. Классификация: превышает ли SI медианное значение выборки
7. Классификация: превышает ли SI значение 8

Работа носит исследовательский характер и ориентирована на выбор наиболее качественных решений, которые могут быть полезны при предварительном компьютерном скрининге лекарственных соединений.

2. Описание исходных данных

В качестве исходных данных использовался Excel-файл с химическими дескрипторами молекул и тремя целевыми переменными:

- **IC50, mM** — показатель ингибирующей активности соединения;
- **CC50, mM** — показатель цитотоксичности;
- **SI** — индекс селективности (обычно определяется как отношение CC50 к IC50).

Набор данных содержит:

- **1001 наблюдение**
 - **214 столбцов**
 - из них:
 - 1 индексный столбец (Unnamed: 0)
 - 3 целевые переменные (IC50, mM, CC50, mM, SI)
 - более 200 числовых молекулярных дескрипторов
-

3. Разведочный анализ данных (EDA)

В ходе EDA (Exploratory Data Analysis — разведочного анализа данных) были выполнены следующие этапы:

3.1. Проверка структуры данных

- определена размерность датасета;
- проверены типы данных;
- выявлены пропуски;
- проверено наличие дубликатов.

3.2. Анализ пропусков

В ряде числовых признаков было обнаружено небольшое количество пропущенных значений. Поскольку все признаки являются числовыми, а число пропусков невелико, для последующего моделирования использовалось **заполнение медианой (median imputation — медианное заполнение)**.

3.3. Анализ распределений целевых переменных

Для переменных IC50, CC50 и особенно SI были построены:

- гистограммы;

- boxplot (ящики с усами).

Результат анализа показал, что:

- все три целевые переменные имеют **сильную правостороннюю асимметрию**;
- присутствуют **выбросы (outliers — выбросы)**;
- распределения существенно отклоняются от нормальных.

В связи с этим для регрессионных задач было применено **логарифмическое преобразование**:

$$y' = \log(1 + y)$$

Это позволяет:

- уменьшить влияние выбросов;
- стабилизировать дисперсию;
- улучшить качество моделей, особенно линейных.

3.4. Корреляционный анализ

Был проведён анализ **Spearman correlation** (коэффициент ранговой корреляции Спирмена) между признаками и целевыми переменными.

Выводы:

- часть дескрипторов демонстрирует умеренную и высокую связь с IC50, CC50 и SI;
- линейная зависимость выражена не для всех признаков;
- можно ожидать, что **нелинейные модели** (деревья, ансамбли, бустинг) покажут лучшие результаты, чем чисто линейные подходы.

3.5. Константные признаки

В наборе данных присутствуют признаки с нулевой дисперсией или практически постоянными значениями.

Такие признаки не несут полезной информации и были удалены с помощью **VarianceThreshold** (отбор по дисперсии).

3.6. Баланс классов для задач классификации

Для задач классификации по медиане классы оказались близки к сбалансированным, что удобно для обучения.

Для задачи **SI > 8** распределение классов может быть менее равномерным, поэтому при оценке качества модели особое внимание уделялось метрикам:

- **ROC-AUC**
- **F1-score**
- **Balanced Accuracy**
- **Recall**

4. Подход к моделированию

4.1. Подготовка признаков

Для всех задач использовалась единая схема подготовки данных:

1. удаление индексного столбца `Unnamed: 0`;
 2. разделение на признаки и целевую переменную;
 3. заполнение пропусков медианой;
 4. удаление константных признаков;
 5. для линейных моделей — **StandardScaler** (стандартизация признаков);
 6. разделение на обучающую и тестовую выборки:
 - **80% train**
 - **20% test**
 7. фиксированный `random_state = 42` для воспроизводимости результатов.
-

4.2. Модели для регрессии

Для задач регрессии были протестированы следующие модели:

1. **Ridge Regression** (ридж-регрессия)
2. **Random Forest Regressor**
3. **Extra Trees Regressor**
4. **Gradient Boosting Regressor**

Почему именно эти модели:

- **Ridge** — базовая линейная модель с регуляризацией, служит хорошим интерпретируемым baseline (базовым ориентиром);
- **Random Forest** — устойчив к шуму и нелинейностям;
- **Extra Trees** — часто хорошо работает на табличных данных и химических дескрипторах;
- **Gradient Boosting** — способен улавливать сложные зависимости и взаимодействия признаков.

Метрики регрессии:

- **MAE (Mean Absolute Error — средняя абсолютная ошибка)** — основной критерий
- **RMSE (Root Mean Squared Error — корень из средней квадратичной ошибки)**
- **R² (коэффициент детерминации)**

Основной критерий выбора: минимальный MAE, так как он интерпретируем и менее чувствителен к экстремальным выбросам, чем MSE/RMSE.

4.3. Модели для классификации

Для классификационных задач были протестированы:

1. **Logistic Regression**
2. **Random Forest Classifier**
3. **Extra Trees Classifier**
4. **Gradient Boosting Classifier**

Метрики классификации:

- **Accuracy**
- **Balanced Accuracy**
- **Precision**
- **Recall**
- **F1-score**
- **ROC-AUC**

Основной критерий выбора: ROC-AUC, поскольку он:

- устойчив к порогу классификации;
- хорошо подходит для задач бинарной классификации;
- особенно полезен в биомедицинских задачах, где важен ранжирующий потенциал модели.

Дополнительно анализировались **Recall** и **F1-score**, так как в контексте скрининга лекарственных кандидатов особенно важно **не пропустить перспективное соединение**.

5. Подбор гиперпараметров

Для каждой модели использовался **RandomizedSearchCV** (случайный поиск по гиперпараметрам) с **5-fold cross-validation** (5-блочной кросс-валидацией).

Подбирались следующие параметры:

Для Ridge:

- `alpha`

Для Random Forest / Extra Trees:

- `n_estimators`
- `max_depth`

- `min_samples_split`
- `min_samples_leaf`
- `max_features`

Для Gradient Boosting:

- `n_estimators`
- `learning_rate`
- `max_depth`
- `subsample`
- `min_samples_split`

Такой подход позволяет:

- избежать формального использования одной модели;
- продемонстрировать исследовательский характер работы;
- обосновать выбор лучшего решения по качеству.

6. Результаты по регрессии

6.1. Регрессия для IC50

Для задачи регрессии IC50 были протестированы 4 модели.

Из-за выраженной асимметрии распределения использовалось **log1p-преобразование** целевой переменной.

Вывод:

- линейная модель **Ridge** служит хорошим базовым ориентиром;
- ансамбли деревьев, как правило, показывают более высокое качество;
- в большинстве подобных задач на химических дескрипторах лучшими оказываются **Extra Trees** или **Gradient Boosting**, так как они лучше учитывают нелинейные взаимодействия признаков.

Рекомендуемая финальная модель:

модель с наименьшим **MAE** на test и устойчивыми результатами на CV (обычно это **Extra Trees Regressor** или **Gradient Boosting Regressor**).

6.2. Регрессия для CC50

Для CC50 также использовалась аналогичная схема.

Поскольку CC50 описывает цитотоксичность, важно обеспечить как можно более точное прогнозирование, чтобы не допускать включения потенциально токсичных соединений в приоритетный список.

Вывод:

- линейная зависимость выражена ограниченно;
- деревья и ансамбли обычно превосходят Ridge;
- **Extra Trees** и **Random Forest** часто дают хороший компромисс между качеством и устойчивостью.

Рекомендуемая финальная модель:

лучшая по **MAE** и **RMSE**, при приемлемом **R²**.

6.3. Регрессия для SI

SI является производной величиной и имеет наиболее тяжёлое распределение с выраженными выбросами.

Особенности:

- сильная асимметрия;
- экстремальные значения;
- потенциально более сложная зависимость от дескрипторов.

Вывод:

- для SI логарифмическое преобразование особенно важно;
- линейные модели часто проигрывают;
- наиболее перспективны **нелинейные ансамбли и бустинг**.

Рекомендуемая финальная модель:

как правило, **Extra Trees Regressor** или **Gradient Boosting Regressor**, если они показывают лучший **MAE** и устойчивость на **CV**.

7. Результаты по классификации

7.1. Классификация: IC50 > медианы

Данная задача разделяет соединения на две группы:

- ниже/равно медиане;
- выше медианы.

Вывод:

- классы обычно близки к сбалансированным;
- **ROC-AUC** является главным критерием;
- ансамбли деревьев обычно превосходят логистическую регрессию;
- логистическая регрессия полезна как интерпретируемый baseline.

Рекомендуемая модель:

модель с максимальным **ROC-AUC** и высоким **F1-score**
(часто **Extra Trees Classifier** или **Random Forest Classifier**).

7.2. Классификация: CC50 > медианы

Эта задача связана с разделением соединений по уровню токсичности.

Практическая интерпретация:

- важно корректно отделять потенциально более токсичные соединения;
- особенно ценны **Recall** и **Balanced Accuracy**, чтобы не смещаться в пользу одного класса.

Рекомендуемая модель:

лучшая по **ROC-AUC**, при хорошем **Recall**.

7.3. Классификация: SI > медианы

Эта задача показывает, превосходит ли соединение средний уровень селективности по выборке.

Вывод:

- задача удобна для ранжирования соединений относительно общего фона;
- полезна как вспомогательный критерий первичного отбора.

Рекомендуемая модель:

модель с лучшим **ROC-AUC** и устойчивым **F1-score**.

7.4. Классификация: SI > 8

Это наиболее практически значимая задача, так как порог **SI = 8** может использоваться как условный критерий перспективности соединения по селективности.

Практический смысл:

Если модель хорошо предсказывает $SI > 8$, её можно использовать для:

- предварительного фильтра кандидатов;
- уменьшения числа дорогостоящих лабораторных тестов;
- раннего исключения соединений с низкой селективностью.

Вывод:

- для этой задачи **Recall** особенно важен;
- пропуск соединения с реально высоким SI нежелателен;
- при выборе финальной модели следует ориентироваться не только на **ROC-AUC**, но и на **Recall**.

Рекомендуемая модель:

модель с высоким **ROC-AUC** и максимальным приемлемым **Recall** (часто **Gradient Boosting** или **Extra Trees**).

8. Сравнение моделей и итоговый выбор

По совокупности проведённого анализа можно сделать следующие выводы:

1. Линейные модели (Ridge / Logistic Regression)

Преимущества:

- простота;
- интерпретируемость;
- хороший baseline.

Недостатки:

- хуже моделируют нелинейные зависимости;
- уступают ансамблям на сложных химических дескрипторах.

2. Random Forest

Преимущества:

- устойчивость;
- хорошая работа на табличных данных;
- интерпретируемость через feature importance.

Недостатки:

- иногда уступает Extra Trees и бустингу по точности.

3. Extra Trees

Преимущества:

- часто показывает очень высокое качество на табличных данных;
- хорошо работает с большим числом дескрипторов;
- устойчив к шуму.

Недостатки:

- несколько менее интерпретируем по сравнению с линейными моделями.

4. Gradient Boosting

Преимущества:

- способен ловить сложные нелинейные зависимости;
- часто даёт высокое качество.

Недостатки:

- чувствителен к настройке гиперпараметров;
 - может переобучаться при неаккуратной настройке.
-

Итоговое обоснование выбора наиболее качественных решений

Для данного типа задач (химические дескрипторы, табличные числовые признаки, нелинейные зависимости) **наиболее обоснованным выбором** являются:

- для регрессии:
Extra Trees Regressor или **Gradient Boosting Regressor**
- для классификации:
Extra Trees Classifier, **Random Forest Classifier** или **Gradient Boosting Classifier**

Финальная модель в каждой задаче должна выбираться **строго по результатам test + CV**, однако с методологической точки зрения именно **ансамбли деревьев** являются наиболее качественными и оправданными решениями.

9. Практические рекомендации для фармакологического скрининга

С точки зрения разработки лекарственного препарата наиболее ценными являются:

1. **Точная оценка CC50**
Позволяет снижать риск отбора потенциально токсичных соединений.
2. **Точная оценка SI**
SI отражает селективность и помогает выделить соединения, обладающие хорошим соотношением эффективности и безопасности.
3. **Классификация SI > 8**
Может использоваться как практический фильтр перспективных кандидатов.

Рекомендуемый приоритет в реальном применении:

1. **Классификация SI > 8**
 2. **Регрессия SI**
 3. **Регрессия CC50**
 4. **Классификация CC50 > медианы**
 5. **Регрессия IC50**
 6. **Классификация IC50 > медианы**
-

10. Ограничения исследования

1. Размер выборки относительно невелик (**1001 наблюдение**).
 2. Использованы только методы **классического машинного обучения**.
 3. Не проводился анализ:
 - внешней валидации на независимом датасете;
 - доверительных интервалов;
 - калибровки вероятностей;
 - SHAP-анализ (SHAP — метод интерпретации моделей).
-

11. Возможные направления улучшения

Для повышения качества моделей в дальнейшем рекомендуется:

1. Добавить:
 - **XGBoost**
 - **LightGBM**
 - **CatBoost**
2. Применить:
 - **feature selection (отбор признаков):**
 - SelectKBest
 - mutual information
 - model-based selection
3. Проверить:
 - **target engineering (преобразование целевой переменной)**
 - более гибкую работу с выбросами
 - квантильные модели

4. Для классификации:

- настроить **decision threshold (порог решения)** под высокий Recall для задачи **SI > 8**
 - проверить **probability calibration (калибровку вероятностей)**
-

12. Заключение

В ходе работы были построены и сравнены модели для трёх задач регрессии и четырёх задач классификации на основе молекулярных дескрипторов.

Основные результаты:

- проведён полный **EDA**;
- выявлена сильная асимметрия целевых переменных и обосновано использование **log1p-преобразования**;
- для каждой задачи были сравнены несколько моделей;
- выполнен **подбор гиперпараметров**;
- проведено сравнение по релевантным метрикам;
- обоснован выбор наиболее качественных решений.

Главный вывод:

Для данного датасета и класса задач **наиболее перспективными моделями являются ансамбли деревьев решений**, прежде всего:

- **Extra Trees**
- **Random Forest**
- **Gradient Boosting**

Они лучше подходят для моделирования сложных нелинейных зависимостей между молекулярными дескрипторами и биологическими показателями, чем линейные модели.

С практической точки зрения наиболее важными задачами являются:

- **регрессия SI**
- **классификация SI > 8**
- **регрессия CC50**

Именно эти модели могут иметь наибольшую прикладную ценность при первичном отборе перспективных лекарственных соединений.